

ĐẠI HỌC BÁCH KHOA
KHOA CÔNG NGHỆ THÔNG TIN



BÁO CÁO XỬ LÝ HỆ THỐNG THÔNG MINH

ĐỀ TÀI:

PHÂN LOẠI CHUYỂN ĐỘNG MẮT DỰA TRÊN GMM-HMM

SINH VIÊN THỰC HIỆN:

Trần Văn Tùng	102220133	22T_DT2
Nguyễn Phan Thành An	102220093	22T_DT2
Nguyễn Phan Thanh	102220126	22T_DT2

GIẢNG VIÊN HƯỚNG DẪN: TS. Ninh Khánh Duy

Đà Nẵng 9/2026

LỜI MỞ ĐẦU

Sự phát triển mạnh mẽ của các hệ thống Tương tác người - máy HCI đang mở ra nhiều phương thức giao tiếp ngày càng trực quan giữa con người và thiết bị. Trong đó, công nghệ theo dõi chuyển động mắt eye-tracking được xem là một phương thức điều khiển không xâm lấn và có tiềm năng ứng dụng cao. Đặc biệt, khi kết hợp với các hệ thống Cánh tay Robot hỗ trợ Assistive Robotic Arms, việc phân tích quỹ đạo ánh nhìn có thể giúp người dùng điều khiển thiết bị một cách tự nhiên hơn mà không cần sử dụng tay.

Tuy nhiên, các hệ thống điều khiển bằng ánh nhìn hiện nay vẫn tồn tại một số hạn chế. Phương pháp lựa chọn mục tiêu bằng ánh nhìn tĩnh gaze-based target selection có thể gây ra bài toán "Midas Touch", tức hệ thống vô tình kích hoạt lệnh khi người dùng nhìn lâu tại một vị trí. Bên cạnh đó, các kỹ thuật phân loại chuyển động mắt truyền thống như I-VT, I-DT hay một số mô hình xác suất cũ còn hạn chế về khả năng thích ứng trong các môi trường động và theo thời gian thực.

Nhằm khắc phục những hạn chế này, báo cáo tập trung nghiên cứu phương pháp phân loại chuyển động mắt dựa trên sự kết hợp giữa Mô hình Hỗn hợp Gaussian và Mô hình Markov Ẩn GMM-HMM. Thuật toán sử dụng K-means kết hợp với độ đo tổng bình phương sai số SSE để hỗ trợ phân đoạn quỹ đạo, sau đó áp dụng quy trình huấn luyện phân cấp để phân biệt ba trạng thái chính gồm fixation, saccades và smooth pursuit.

Phương pháp đề xuất đạt độ chính xác 94,39%. Khi được tích hợp vào hệ thống robot, phương pháp còn hỗ trợ lập kế hoạch đường đi động dựa trên ánh nhìn với thời gian trung bình 2,97 mili-giây. Qua đó, đề tài hướng đến xây dựng một phương thức tương tác người - máy trực quan, linh hoạt và hiệu quả hơn trong các ứng dụng thực tế.

MỤC LỤC

LỜI MỞ ĐẦU	1
1. GIỚI THIỆU BÀI TOÁN	4
1.1. Tổng quan đề tài	4
1.2. Các thách thức tồn đọng	4
1.3. Giải pháp đề xuất	5
2. CƠ SỞ LÝ THUYẾT NỀN TẢNG	6
2.1. Gaussian Mixture Model	6
2.1.1. Khái niệm mô hình GMM	6
2.1.2. Hàm mục tiêu trong mô hình GMM	8
2.1.3. Thuật toán Expectation-Maximization	9
2.2. K-Means Clustering	11
2.2.1. Khái niệm mô hình K-Means	11
2.2.2. Hàm mục tiêu trong mô hình K-Means	12
2.2.3. Thuật toán K-Means	13
2.3. Hidden Markov Model.....	14
2.3.1. Chuỗi Markov.....	14
2.3.2. Mô hình Markov ẩn	14
2.3.3. Ba vấn đề cơ bản của HMM.....	15
2.3.4. Bài toán Evaluation	15
2.3.5. Bài toán Decoding.....	16
2.3.6. Bài toán Decoding.....	16

2.4. Kết hợp GMM và HMM.....	17
3. ỨNG DỤNG TRONG BÀI TOÁN PHÂN LOẠI CHUYỂN ĐỘNG MẮT	18
3.1. Bài toán chuyển động mắt	18
3.2. Dữ liệu sử dụng.....	18
3.3. Pipeline xử lý bài toán.....	20
3.4. Kết quả thực nghiệm	23
4. KẾT LUẬN	27
5. TÀI LIỆU THAM KHẢO	28

1. GIỚI THIỆU BÀI TOÁN

1.1. Tổng quan đề tài

Một trong những ứng dụng mang tính nhân văn và đột phá nhất của công nghệ eye-tracking là việc tích hợp vào các hệ thống Cánh tay Robot hỗ trợ. Đối với môi trường công nghiệp, nó giúp người lao động thao tác hệ thống máy móc từ xa một cách hiệu quả, giảm thiểu áp lực thể chất. Trong lĩnh vực y tế và phục hồi chức năng, công nghệ này trao quyền cho những bệnh nhân suy giảm chức năng vận động khả năng tự chủ. Chỉ bằng ánh nhìn, họ có thể tương tác với môi trường xung quanh và thực hiện các tác vụ sinh hoạt thiết yếu với nỗ lực vật lý tối thiểu.

Tuy nhiên, để biến ánh nhìn thành các lệnh điều khiển robot chính xác và an toàn, hệ thống đòi hỏi một cơ sở tính toán thông minh đủ mạnh để phân tích, bóc tách và hiểu được ý định thực sự của người dùng thông qua chuỗi tín hiệu mắt theo thời gian thực. Điều này đặt ra yêu cầu cấp thiết về việc xây dựng các mô hình học máy có khả năng phân loại chính xác các trạng thái sinh học của mắt. Nhận thức được tầm quan trọng đó, đề tài này được thực hiện nhằm đi sâu vào nghiên cứu và ứng dụng các thuật toán thông minh trong bài toán phân loại chuyển động mắt, hướng tới việc xây dựng các hệ thống điều khiển robot động hiệu quả, trực quan và giải quyết những giới hạn của các phương pháp tương tác truyền thống.

1.2. Các thách thức tồn đọng

Mặc dù công nghệ theo dõi chuyển động mắt eye-tracking mang lại nhiều tiềm năng trong điều khiển robot, việc triển khai thực tế vẫn gặp một số thách thức khiến quá trình tương tác chưa thực sự tự nhiên và mượt mà.

Thứ nhất là vấn đề Midas Touch. Hệ thống có thể nhầm một ánh nhìn thông thường thành lệnh điều khiển. Để hạn chế điều này, nhiều hệ thống yêu cầu người dùng duy trì fixation trong một khoảng thời gian nhất định mới xác nhận mục tiêu. Tuy nhiên, cách này làm giảm tốc độ tương tác và có thể gây mỏi mắt khi sử dụng lâu.


Thứ hai là sự hạn chế của các thuật toán phân loại truyền thống. Các phương pháp như I-VT và I-DT thường dựa trên các ngưỡng cố định để phân biệt các trạng thái chuyển động mắt. Điều này làm giảm khả năng thích ứng giữa những người dùng và điều kiện khác nhau. Các mô hình xác suất như I-BDT linh hoạt hơn nhưng vẫn phụ

thuộc vào các giả định và thông tin tiên nghiệm. Đặc biệt, việc phân biệt fixation với smooth pursuit vẫn là một bài toán khó.

Thứ ba là độ trễ trong xử lý thời gian thực. Nhiều hệ thống hiện tại tách quá trình điều khiển thành hai bước gồm xác định mục tiêu bằng ánh nhìn và sau đó lập kế hoạch đường đi cho robot. Sự tách rời này có thể tạo ra độ trễ đáng kể, làm giảm tính liên tục và tự nhiên trong quá trình điều khiển robot bằng ánh nhìn.

1.3. Giải pháp đề xuất

Để giải quyết các thách thức trên, hệ thống đề xuất được xây dựng gồm ba khối chức năng chính, tương ứng với quá trình thu nhận dữ liệu, xử lý thông tin và thực thi điều khiển robot:



Thứ nhất là khối thu thập dữ liệu Data Acquisition Block. Khối này sử dụng thiết bị Eye Tracker để ghi nhận liên tục tọa độ ánh nhìn x, y và vận tốc chuyển động mắt v . Bên cạnh đó, camera chiều sâu 3D được sử dụng để thu nhận thông tin không gian của môi trường, bao gồm ảnh và bản đồ chiều sâu. Các dữ liệu này tạo thành đầu vào cho quá trình phân tích hành vi ánh nhìn và xác định vị trí mục tiêu trong không gian ba chiều.

Thứ hai là khối xử lý trung tâm Central Processing Block. Tại đây, dữ liệu ảnh nhìn được tiền xử lý, phân đoạn và phân tích theo chuỗi thời gian. K-means được sử dụng trong bước phân đoạn quỹ đạo dựa trên đặc trưng không gian và giá trị SSE, sau đó mô hình GMM-HMM thực hiện phân loại các trạng thái chuyển động mắt như fixation, saccade và smooth pursuit. Đồng thời, dữ liệu chiều sâu được tích hợp để chuyển đổi tọa độ ảnh nhìn từ không gian ảnh 2D sang tọa độ 3D trong hệ tọa độ của robot. Từ đó, hệ thống xác định mục tiêu và hỗ trợ xây dựng quỹ đạo chuyển động phù hợp.

Thứ ba là khối thực thi Execution Block. Khối này tiếp nhận quỹ đạo và các lệnh điều khiển từ khối xử lý trung tâm để điều khiển cánh tay robot thực hiện các thao tác như di chuyển và gấp vật thể. Trong thực nghiệm của paper, phương pháp đề xuất đạt thời gian lập kế hoạch trung bình khoảng 2,97 mili-giây, cho thấy khả năng đáp ứng tốt đối với các tác vụ điều khiển theo thời gian thực. Nhờ sự phối hợp giữa ba khối, hệ thống có thể tạo ra quá trình tương tác bằng ảnh nhìn trực quan và liên tục hơn.

2. CƠ SỞ LÝ THUYẾT NỀN TẢNG

2.1. Gaussian Mixture Model

2.1.1. Khái niệm mô hình GMM

Gaussian Mixture Model là mô hình xác suất biểu diễn phân phối dữ liệu tổng thể dưới dạng sự kết hợp tuyến tính của K phân phối Gauss đa biến thành phần. Mỗi thành phần Gaussian đại diện cho một cụm phân bố tích tụ trong không gian đặc trưng.

Với vector đặc trưng D -chiều $\mathbf{x} \in \mathbb{R}^D$, hàm mật độ xác suất của GMM được xác định bởi:

$$p(\mathbf{x} | \theta) = \sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x} | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)$$

Trong đó:

- $\mathbf{x}$: vector dữ liệu quan sát có D chiều.
- D : số chiều của không gian đặc trưng.

- K : số thành phần Gaussian trong mô hình.
- π_k : hệ số trộn của thành phần Gaussian thứ k .
- $\boldsymbol{\mu}_k$: vector trung bình của thành phần Gaussian thứ k .
- $\boldsymbol{\Sigma}_k$: ma trận hiệp phương sai của thành phần Gaussian thứ k .
- $\mathcal{N}(\mathbf{x} \mid \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)$: hàm mật độ xác suất Gaussian đa biến của thành phần thứ k .
- θ : tập hợp toàn bộ tham số của mô hình GMM.

Các hệ số trộn phải thỏa mãn:

$$\pi_k \geq 0, \quad \sum_{k=1}^K \pi_k = 1$$

Hàm mật độ xác suất của phân phối Gaussian đa biến được xác định bởi:

$$\mathcal{N}(\mathbf{x} \mid \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) = \frac{1}{(2\pi)^{D/2} |\boldsymbol{\Sigma}_k|^{1/2}} \exp \left[-\frac{1}{2} (\mathbf{x} - \boldsymbol{\mu}_k)^T \boldsymbol{\Sigma}_k^{-1} (\mathbf{x} - \boldsymbol{\mu}_k) \right]$$

Trong đó:

- $|\boldsymbol{\Sigma}_k|$: định thức của ma trận hiệp phương sai.
- $\boldsymbol{\Sigma}_k^{-1}$: ma trận nghịch đảo của ma trận hiệp phương sai.
- $(\mathbf{x} - \boldsymbol{\mu}_k)^T$: chuyển vị của vector sai lệch giữa điểm dữ liệu và vector trung bình.

Vector trung bình $\boldsymbol{\mu}_k \in \mathbb{R}^D$ xác định vị trí trung tâm của thành phần Gaussian, còn ma trận hiệp phương sai $\boldsymbol{\Sigma}_k \in \mathbb{R}^{D \times D}$ mô tả mức độ phân tán và mối tương quan giữa các đặc trưng.

2.1.2. Hàm mục tiêu trong mô hình GMM

Cho tập dữ liệu gồm N mẫu quan sát:

$$X = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N\}$$

Trong đó:

- X : toàn bộ tập dữ liệu quan sát.
- N : số lượng mẫu trong tập dữ liệu.
- $\mathbf{x}_n$: mẫu dữ liệu thứ n .

Tập tham số của mô hình GMM được ký hiệu là:

$$\theta = \{\pi_k, \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k\}_{k=1}^K$$

Mục tiêu của GMM là tìm bộ tham số θ sao cho xác suất sinh ra tập dữ liệu quan sát là lớn nhất. Giả sử các mẫu dữ liệu độc lập với nhau, hàm hợp lý được xác định bởi:

$$L(\theta) = \prod_{n=1}^N p(\mathbf{x}_n | \theta) = \prod_{n=1}^N \left[\sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x}_n | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \right]$$

Trong đó:

- $L(\theta)$: hàm hợp lý của mô hình đối với tập dữ liệu quan sát.
- $p(\mathbf{x}_n | \theta)$: mật độ xác suất của mẫu $\mathbf{x}_n$ theo mô hình GMM.
- N : số lượng mẫu dữ liệu.
- K : số thành phần Gaussian.

Bài toán ước lượng tham số GMM được biểu diễn dưới dạng:

$$\theta^* = \underset{\theta}{\operatorname{argmax}} L(\theta)$$

Trong thực tế, hàm log-likelihood thường được sử dụng để thuận tiện cho quá trình tối ưu:

$$\ell(\theta) = \log L(\theta) = \sum_{n=1}^N \log \left[\sum_{k=1}^K \pi_k \mathcal{N}(\mathbf{x}_n | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \right]$$

Trong đó:

- θ^* : bộ tham số tối ưu của mô hình.
- argmax : phép toán tìm giá trị tham số làm hàm mục tiêu đạt giá trị lớn nhất.
- $\ell(\theta)$: hàm log-likelihood của mô hình.
- $\log(\cdot)$: hàm logarithm tự nhiên.

Do tồn tại tổng của nhiều phân phối Gaussian bên trong hàm logarithm, việc tối ưu trực tiếp các tham số không thuận tiện. Vì vậy, thuật toán Expectation-Maximization được sử dụng để ước lượng các tham số của GMM.

2.1.3. Thuật toán Expectation-Maximization

Expectation-Maximization là thuật toán lặp dùng để ước lượng tham số của mô hình xác suất có chứa biến ẩn. Đối với GMM, biến ẩn z_n biểu diễn thành phần Gaussian sinh ra mẫu $\mathbf{x}_n$:

$$z_n \in \{1, 2, \dots, K\}$$

Trong đó $z_n = k$ cho biết mẫu $\mathbf{x}_n$ được gán cho thành phần Gaussian thứ k .

Bước E - Expectation. Xác suất hậu nghiệm để thành phần Gaussian thứ k sinh ra mẫu dữ liệu thứ n được tính bởi:

$$\gamma_{nk} = P(z_n = k | \mathbf{x}_n) = \frac{\pi_k \mathcal{N}(\mathbf{x}_n | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)}{\sum_{j=1}^K \pi_j \mathcal{N}(\mathbf{x}_n | \boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)}$$

Trong đó:

- γ_{nk} : responsibility của thành phần Gaussian thứ k đối với mẫu thứ n .
- $P(z_n = k | \mathbf{x}_n)$: xác suất hậu nghiệm mẫu $\mathbf{x}_n$ thuộc thành phần thứ k .
- j : chỉ số chạy qua tất cả các thành phần Gaussian.

Với mỗi mẫu $\mathbf{x}_n$, tổng các responsibility thỏa mãn:

$$\sum_{k=1}^K \gamma_{nk} = 1$$

Số lượng mẫu hiệu dụng của thành phần thứ k được xác định bởi:

$$N_k = \sum_{n=1}^N \gamma_{nk}$$

Trong đó N_k là số lượng mẫu hiệu dụng được gán cho thành phần Gaussian thứ k .

Bước M - Maximization. Các tham số của GMM được cập nhật dựa trên các giá trị γ_{nk} thu được từ bước E:

$$\boldsymbol{\mu}_k^{\text{new}} = \frac{1}{N_k} \sum_{n=1}^N \gamma_{nk} \mathbf{x}_n$$

$$\boldsymbol{\Sigma}_k^{\text{new}} = \frac{1}{N_k} \sum_{n=1}^N \gamma_{nk} (\mathbf{x}_n - \boldsymbol{\mu}_k^{\text{new}})(\mathbf{x}_n - \boldsymbol{\mu}_k^{\text{new}})^T$$

$$\pi_k^{\text{new}} = \frac{N_k}{N}$$

Trong đó:

- $\boldsymbol{\mu}_k^{\text{new}}$: vector trung bình mới của thành phần Gaussian thứ k .
- $\boldsymbol{\Sigma}_k^{\text{new}}$: ma trận hiệp phương sai mới của thành phần Gaussian thứ k .
- π_k^{new} : hệ số trộn mới của thành phần Gaussian thứ k .
- N_k : số lượng mẫu hiệu dụng của thành phần Gaussian thứ k .

- N : tổng số mẫu dữ liệu.

Hai bước E và M được thực hiện luân phiên cho đến khi hàm log-likelihood hội tụ hoặc mức thay đổi giữa hai vòng lặp liên tiếp nhỏ hơn một ngưỡng xác định.

2.2. K-Means Clustering

2.2.1. Khái niệm mô hình K-Means

K-Means là thuật toán phân cụm không giám sát, được sử dụng để phân chia tập dữ liệu thành K cụm sao cho các điểm dữ liệu trong cùng một cụm có mức độ tương đồng cao và khoảng cách đến tâm cụm tương ứng là nhỏ. Mỗi cụm được đại diện bởi một vector tâm cụm, được xác định bằng giá trị trung bình của các điểm dữ liệu thuộc cụm đó.

Cho tập dữ liệu gồm N mẫu quan sát:

$$X = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N\}, \quad \mathbf{x}_n \in \mathbb{R}^D$$

Trong K-Means, mỗi điểm dữ liệu được gán duy nhất vào một cụm dựa trên khoảng cách đến các tâm cụm. Khoảng cách Euclid thường được sử dụng để xác định tâm cụm gần nhất.

$$c_n = \arg \min_{k \in \{1, \dots, K\}} \|\mathbf{x}_n - \boldsymbol{\mu}_k\|_2^2$$

Trong đó:

- X : toàn bộ tập dữ liệu quan sát.
- N : số lượng mẫu trong tập dữ liệu.
- $\mathbf{x}_n$: vector đặc trưng của mẫu dữ liệu thứ n .
- D : số chiều của không gian đặc trưng.
- K : số lượng cụm cần phân chia.
- C_k : tập hợp các điểm dữ liệu thuộc cụm thứ k .

- μ_k : vector tâm của cụm thứ k .

2.2.2. Hàm mục tiêu trong mô hình K-Means

Mục tiêu của K-Means là tìm cách phân chia dữ liệu và xác định các tâm cụm sao cho tổng bình phương khoảng cách từ mỗi điểm dữ liệu đến tâm của cụm mà nó thuộc về là nhỏ nhất. Hàm mục tiêu được xác định bởi:

$$J = \sum_{k=1}^K \sum_{\mathbf{x}_n \in C_k} \|\mathbf{x}_n - \mu_k\|_2^2$$

Trong đó:

- J : giá trị hàm mục tiêu của K-Means.
- K : số lượng cụm.
- C_k : tập hợp các điểm dữ liệu thuộc cụm thứ k .
- $\mathbf{x}_n$: vector dữ liệu thứ n thuộc cụm C_k .
- μ_k : vector tâm của cụm thứ k .
- $\|\mathbf{x}_n - \mu_k\|_2^2$: bình phương khoảng cách Euclid giữa điểm dữ liệu $\mathbf{x}_n$ và tâm cụm μ_k .

Bài toán tối ưu của K-Means có thể được biểu diễn dưới dạng:

$$\arg \min_{\{C_k\}, \{\mu_k\}} J$$

Giá trị của hàm mục tiêu còn được gọi là Sum of Squared Errors (SSE):

$$SSE = \sum_{k=1}^K \sum_{\mathbf{x}_n \in C_k} \|\mathbf{x}_n - \mu_k\|_2^2$$

Trong đó SSE biểu diễn tổng sai số bình phương bên trong các cụm. Giá trị SSE càng nhỏ cho thấy các điểm dữ liệu nằm càng gần tâm cụm tương ứng và các cụm có độ tập trung cao hơn.

2.2.3. Thuật toán K-Means

Thuật toán K-Means tối ưu hàm mục tiêu bằng quá trình lặp gồm bước gán cụm và bước cập nhật tâm cụm. Trước khi bắt đầu quá trình lặp, K tâm cụm ban đầu được lựa chọn từ tập dữ liệu.

Bước 1 - Khởi tạo. Lựa chọn K vector tâm cụm ban đầu:

$$\mu_1, \mu_2, \dots, \mu_K$$

Bước 2 - Gán cụm. Với mỗi điểm dữ liệu $\mathbf{x}_n$, xác định cụm có tâm gần nhất theo khoảng cách Euclid:

$$c_n = \underset{k \in \{1, 2, \dots, K\}}{\operatorname{argmin}} \|\mathbf{x}_n - \mu_k\|_2^2$$

Bước 3 - Cập nhật tâm cụm. Sau khi các điểm dữ liệu được gán vào các cụm, tâm của mỗi cụm được cập nhật bằng trung bình của tất cả các điểm thuộc cụm đó:

$$\mu_k = \frac{1}{|C_k|} \sum_{\mathbf{x}_n \in C_k} \mathbf{x}_n$$

Trong đó:

- $\mathbf{x}_n$: vector dữ liệu thứ n .
- $|C_k|$: số lượng điểm dữ liệu thuộc cụm thứ k .
- μ_k : vector tâm mới của cụm thứ k .
- $\mathbf{x}_n$: vector dữ liệu thuộc cụm C_k .

Bước 4 - Kiểm tra hội tụ. Hai bước gán cụm và cập nhật tâm cụm được thực hiện lặp lại cho đến khi các tâm cụm không còn thay đổi đáng kể, việc gán cụm không thay đổi hoặc đạt đến số vòng lặp tối đa.

Sau khi thuật toán hội tụ, mỗi điểm dữ liệu thuộc về một trong K cụm và các tâm cụm là nghiệm cục bộ của hàm mục tiêu.

2.3. Hidden Markov Model

2.3.1. Chuỗi Markov

Chuỗi Markov mô tả sự biến đổi của một hệ thống qua các trạng thái theo thời gian. Gọi $S = \{s_1, s_2, \dots, s_N\}$ là tập trạng thái và q_t là trạng thái tại thời điểm t . Với chuỗi Markov bậc một, khi đã biết trạng thái ngay trước đó, các trạng thái xa hơn trong quá khứ không cung cấp thêm thông tin để dự đoán trạng thái hiện tại:


$$P(q_t = s_j \mid q_{t-1} = s_i, q_{t-2}, \dots, q_1) = P(q_t = s_j \mid q_{t-1} = s_i).$$

Mô hình được xác định bởi phân phối ban đầu π và ma trận chuyển trạng thái A . Trong đó, $\pi_i = P(q_1 = s_i)$ là xác suất bắt đầu ở trạng thái s_i , còn:

$$a_{ij} = P(q_t = s_j \mid q_{t-1} = s_i)$$

là xác suất chuyển từ s_i sang s_j . Các giá trị xác suất không âm và thỏa mãn $\sum_i \pi_i = 1, \sum_j a_{ij} = 1$ với mọi i .

	A	B	C
A	0.1	0.6	0.3
B	0.4	0.3	0.3
C	0.2	0.5	0.3




2.3.2. Mô hình Markov ẩn

Trong HMM, chuỗi trạng thái $Q = (q_1, \dots, q_T)$ không được quan sát trực tiếp. Tại mỗi thời điểm, trạng thái q_t sinh ra một quan sát O_t , tạo thành chuỗi $O = (O_1, \dots, O_T)$. HMM giữ giả định Markov bậc một đối với trạng thái và giả định rằng quan sát chỉ phụ thuộc vào trạng thái hiện tại khi đã biết trạng thái ấy:

$$P(q_t \mid q_1, \dots, q_{t-1}) = P(q_t \mid q_{t-1}), \quad p(O_t \mid Q, O_1, \dots, O_{t-1}) = p(O_t \mid q_t).$$

Mô hình thường được ký hiệu $\lambda = (\pi, A, B)$, trong đó π là phân phối trạng thái ban đầu, A là ma trận chuyển trạng thái (transition matrix) và B là tập phân phối phát

xạ (emission matrix). Với trạng thái s_j , phân phối phát xạ được ký hiệu $b_j(o) = p(O_t = o \mid q_t = s_j)$. Khi quan sát liên tục, $b_j(o)$ là một mật độ xác suất.



2.3.3. Ba vấn đề cơ bản của HMM

Từ mô hình λ và chuỗi quan sát O , lý thuyết HMM đặt ra ba bài toán: Evaluation Decoding và Learning. Chúng khác nhau ở đại lượng cần xác định: likelihood của quan sát, chuỗi trạng thái ẩn, hoặc tham số của mô hình.

Bài toán	Câu hỏi chính	Kết quả cần tìm	Phương pháp tiêu biểu
Evaluation	Mô hình giải thích chuỗi quan sát tốt đến mức nào?	$p(O \mid \lambda)$	Forward hoặc Backward
Decoding	Chuỗi trạng thái ẩn nào phù hợp nhất với quan sát?	Q^*	Viterbi; Forward–Backward cho hậu nghiệm từng thời điểm
Learning	Ước lượng các tham số HMM từ dữ liệu như thế nào?	λ^*	Baum–Welch (EM)

2.3.4. Bài toán Evaluation

Khi các tham số λ đã biết, Evaluation xác định likelihood của chuỗi quan sát. Vì trạng thái ẩn không được biết trước, cần cộng xác suất đồng thời trên tất cả chuỗi trạng thái có thể xảy ra:

$$p(O \mid \lambda) = \sum_Q p(O, Q \mid \lambda).$$

Nếu liệt kê trực tiếp, số chuỗi cần xét tăng theo N^T với N trạng thái và T thời điểm. Forward giải quyết vấn đề bằng quy hoạch động: tại mỗi thời điểm, thuật toán cộng gộp xác suất của các đường đi cùng kết thúc ở một trạng thái. Backward thực hiện phép tính tương ứng theo chiều ngược, bắt đầu từ cuối chuỗi. Hai thuật toán cho cùng một likelihood và có thể được kết hợp trong các bài toán suy luận, huấn luyện. Với chuỗi dài, phép tính thường được chuẩn hóa hoặc thực hiện trong miền log để tránh sai số số học.

2.3.5. Bài toán Decoding

Decoding là bài toán suy luận chuỗi trạng thái ẩn khi đã biết chuỗi quan sát và mô hình HMM. Nói cách khác, từ các dữ liệu quan sát được, ta cần xác định hệ thống có khả năng đã đi qua những trạng thái ẩn nào.

Một phương pháp phổ biến để giải quyết bài toán này là thuật toán Viterbi. Thuật toán tìm toàn bộ chuỗi trạng thái ẩn có khả năng xảy ra cao nhất:

$$Q^* = \operatorname{argmax}_Q P(Q \mid O, \lambda)$$

Thay vì thử tất cả các chuỗi trạng thái có thể có, Viterbi sử dụng quy hoạch động để lưu lại đường đi có xác suất cao nhất tại mỗi thời điểm. Sau khi xử lý hết chuỗi quan sát, thuật toán truy vết ngược để xác định chuỗi trạng thái tối ưu.

2.3.6. Bài toán Decoding

Learning được đặt ra khi π , A và B chưa biết. Mục tiêu là tìm bộ tham số giải thích tốt dữ liệu quan sát, thường thông qua cực đại hóa log-likelihood:

$$\lambda^* = \operatorname{argmax}_{\lambda} \log p(O \mid \lambda).$$

Baum–Welch là cách áp dụng thuật toán Expectation–Maximization (EM) cho HMM. Ở bước E, mô hình dùng Forward–Backward để ước lượng xác suất hậu nghiệm của trạng thái và các lần chuyển trạng thái. Ở bước M, những giá trị này được dùng để cập nhật phân phối ban đầu, ma trận chuyển trạng thái và tham số phát xạ. Hai bước được lặp cho đến khi likelihood hội tụ hoặc đạt giới hạn vòng lặp. Kết quả có thể phụ thuộc vào cách khởi tạo vì EM có thể hội tụ đến cực trị cục bộ.

2.4. Kết hợp GMM và HMM


Trong HMM, mỗi trạng thái ẩn cần xác định một phân phối phát xạ (emission distribution) để mô tả xác suất của dữ liệu quan sát khi hệ thống đang ở trạng thái đó. Đối với dữ liệu liên tục, phân phối phát xạ có thể được mô hình hóa bằng Gaussian Mixture Model.

$$b_j(o) = \sum_{k=1}^K w_{jk} \mathcal{N}(o | \mu_{jk}, \Sigma_{jk}), \quad w_{jk} \geq 0, \quad \sum_{k=1}^K w_{jk} = 1.$$

Trong đó, K là số thành phần Gaussian; w_{jk} , μ_{jk} và Σ_{jk} lần lượt là trọng số, vector trung bình và ma trận hiệp phương sai của thành phần thứ k thuộc trạng thái j . Với hiệp phương sai đầy đủ, mô hình có thể biểu diễn tương quan giữa vị trí và vận tốc.

Như vậy, trong GMM-HMM, HMM đảm nhiệm việc mô hình hóa sự chuyển đổi giữa các trạng thái ẩn theo thời gian, trong khi mỗi trạng thái ẩn sử dụng một GMM để mô hình hóa phân phối của dữ liệu quan sát.

Hình bên dưới mô tả tổng quan kết hợp GMM-HMM trong bài toán chuyển động mắt.



3. ỨNG DỤNG TRONG BÀI TOÁN PHÂN LOẠI CHUYỂN ĐỘNG MẮT

3.1. Bài toán chuyển động mắt

Tín hiệu đầu vào là chuỗi dữ liệu liên tục từ Eye Tracker, gồm tọa độ điểm nhìn (x, y) và vận tốc chuyển động mắt v . Mục tiêu của bài toán là phân loại dữ liệu thành ba trạng thái chuyển động mắt chính:

- Fixation: mắt gần như cố định tại một vị trí, vận tốc thấp.
- Saccade: mắt di chuyển nhanh và đột ngột giữa các vị trí, vận tốc cao.
- Smooth Pursuit: mắt di chuyển liên tục để theo dõi mục tiêu, với vận tốc tương đối ổn định.

Bài toán được xem như một bài toán phân loại chuỗi, trong đó mỗi điểm hoặc đoạn tín hiệu cần được gán vào một trong ba trạng thái trên. Khó khăn chính nằm ở sự chồng lấn đặc trưng giữa các trạng thái, đặc biệt giữa Fixation và Smooth Pursuit, cũng như sự khác biệt về đặc tính chuyển động mắt giữa các người dùng. Vì vậy, mô hình GMM-HMM được sử dụng để khai thác đồng thời phân phối đặc trưng và quan hệ chuyển trạng thái theo thời gian.

3.2. Dữ liệu sử dụng

Tập dữ liệu sử dụng trong nghiên cứu này được nhóm tác giả của paper "GMM-HMM-Based Eye Movement Classification for Efficient and Intuitive Dynamic Human - Computer Interaction Systems" công bố công khai [1] nhằm phục vụ mục đích tái lập kết quả (reproducibility) và tạo điều kiện cho cộng đồng nghiên cứu tiếp tục phát triển. Dữ liệu được lưu trữ tại kho GitHub [2].

Quy mô thu thập: Dữ liệu được thu thập từ 18 người tham gia thí nghiệm (tester), độ tuổi từ 20 đến 24, có thị lực bình thường hoặc đã hiệu chỉnh về mức bình thường. Thiết bị ghi nhận là Tobii Eye Tracker 4c, hoạt động ở tần số lấy mẫu 90 Hz, được đặt cố định bên dưới màn hình hiển thị trong quá trình thí nghiệm. Toàn bộ tập dữ liệu gồm 87 file ghi nhận (mỗi tester được yêu cầu thực hiện nhiều lượt quan sát mục tiêu kích thích dạng bước nhảy 2D - 2D step target - xuất hiện lần lượt ở các hướng khác nhau trên màn hình, tạo thành nhiều file dữ liệu riêng biệt cho mỗi người).

Cấu trúc dữ liệu: Mỗi file dữ liệu là một chuỗi thời gian, với các cột lần lượt là:


Cột	Ý nghĩa
x	Tọa độ điểm nhìn theo trục ngang
y	Tọa độ điểm nhìn theo trục dọc
velocity	Vận tốc chuyển động của điểm nhìn tại thời điểm tương ứng
manual label	Nhãn hành vi chuyển động mắt được gán thủ công (0/1/2 tương ứng Fixation / Smooth Pursuit / Saccade)

Nhãn manual_label được gán bằng phương pháp quan sát thủ công theo quy trình mô tả bởi Komogortsev - dựa trên việc kiểm tra trực quan các thành phần chuyển động ngang, dọc và trong một số trường hợp khó phân biệt, kết hợp thêm góc nhìn quỹ đạo 3D - nên có thể tồn tại một mức độ chủ quan nhất định trong quá trình gán nhãn, như chính paper gốc cũng đã lưu ý.

X	Y	V	Label
0.520830	0.133245	0.000013	0
0.520664	0.133012	0.000026	0
0.520266	0.132906	0.000037	0
0.519996	0.132970	0.000025	0
0.519874	0.133241	0.000027	0
0.519553	0.133601	0.000044	0
0.519322	0.133881	0.000033	0
0.519262	0.134014	0.000013	0
0.519211	0.134185	0.000016	0
0.519175	0.134123	0.000007	0
0.519277	0.134199	0.000012	0
0.519514	0.133940	0.000032	0
0.519686	0.133350	0.000056	0

3.3. Pipeline xử lý bài toán

Quy trình xử lý được xây dựng theo hướng phân cấp, trong đó dữ liệu chuyển động mắt được phân đoạn trước khi thực hiện phân loại chi tiết. Cách tổ chức này giúp giảm ảnh hưởng của sự chồng lấn đặc trưng không gian và khai thác đồng thời thông tin tọa độ và vận tốc của ánh nhìn.




Bước 1. Phân đoạn quỹ đạo bằng K-Means và SSE.

Thuật toán K-Means được áp dụng trên tọa độ ánh nhìn x và y với nhiều giá trị k khác nhau (k là số cụm cần chia). Tại mỗi giá trị k , tổng bình phương sai số được tính theo công thức SSE nhằm đánh giá mức độ phân tán của các cụm. Phương pháp Elbow được sử dụng để lựa chọn số cụm phù hợp, từ đó chia quỹ đạo ánh nhìn thành các đoạn nhỏ có đặc trưng không gian tương đối đồng nhất.

Bước 2. Phân loại GMM-HMM tầng thứ nhất.


Sau bước phân đoạn, các đoạn dữ liệu được đưa vào mô hình GMM-HMM để thực hiện phân loại thô. Theo mô tả của bài báo, tầng thứ nhất tập trung vào các đặc trưng tọa độ (x, y) nhằm khai thác cấu trúc không gian của quỹ đạo. Mô hình HMM được biểu diễn bởi bộ tham số $\lambda = \{A, B, \pi\}$, trong đó A là ma trận xác suất chuyển trạng thái, B là ma trận xác suất phát xạ (liên kết trạng thái ẩn với dữ liệu quan sát), π

là phân phối xác suất trạng thái ban đầu. Các tham số này được ước lượng bằng thuật toán Baum-Welch, còn chuỗi trạng thái ẩn được xác định bằng thuật toán Viterbi. Kết quả đầu ra của tầng thứ nhất là các đoạn quỹ đạo đã được phân vào k cụm dựa trên đặc trưng không gian — đây mới chỉ là kết quả phân loại thô, chưa phân biệt cụ thể hành vi mắt, và sẽ được đưa tiếp vào tầng thứ hai để tinh chỉnh.



Bước 3. Phân loại GMM-HMM tầng thứ hai.


Với mỗi cụm k thu được từ tầng thứ nhất, một mô hình GMM-HMM thứ hai được khởi tạo và huấn luyện riêng biệt, ký hiệu là $\lambda_k = \{A_k, B_k, \pi_k\}$ — tức là mỗi cụm k có bộ tham số HMM (ma trận chuyển trạng thái A_k , ma trận phát xạ B_k , phân phối trạng thái ban đầu π_k) của riêng nó, khác với λ chung dùng ở tầng thứ nhất. Lần này, đặc trưng đầu vào là vận tốc v thay vì tọa độ (x, y) . Tương tự tầng 1, các tham số λ_k được ước lượng bằng thuật toán Baum-Welch, và chuỗi trạng thái ẩn ứng với mỗi cụm được giải mã bằng thuật toán Viterbi, nhằm phân biệt chi tiết hơn ba hành vi chuyển động mắt gồm Fixation, Saccade và Smooth Pursuit. Kết quả phân loại của từng cụm k được lưu lại thành $\text{states}[k]$. Việc kết hợp đặc trưng không gian (x, y) ở tầng đầu và đặc trưng vận tốc v ở tầng sau — mỗi tầng có mô hình HMM riêng — giúp cải thiện khả năng phân loại các trạng thái có biểu hiện tương đối giống nhau.



Bước 4. Hợp nhất kết quả phân loại.


Sau khi từng đoạn dữ liệu được phân loại, các kết quả được sắp xếp lại theo đúng thứ tự thời gian ban đầu để tạo thành chuỗi nhãn hoàn chỉnh. Kết quả cuối cùng biểu diễn trạng thái chuyển động mắt tại từng thời điểm trong toàn bộ chuỗi quan sát.

Như vậy, pipeline tổng thể gồm bốn giai đoạn liên tiếp: phân đoạn quỹ đạo bằng K-Means và SSE, phân loại GMM-HMM tầng thứ nhất, phân loại GMM-HMM tầng thứ hai và hợp nhất kết quả. Cấu trúc phân cấp này là thành phần chính giúp mô hình khai thác hiệu quả cả đặc trưng không gian lẫn đặc trưng động học của chuyển động mắt.



3.4. Kết quả thực nghiệm

a) Kết quả từ code paper cung cấp



Xét theo từng lớp hành vi, chênh lệch tập trung rõ nhất ở lớp Smooth Pursuit (F1 chỉ đạt 17.5% so với 88.9% của paper - mức tụt sâu nhất), trong khi Fixation (68.3% so với 97.0%) và Saccade (47.9% so với 90.8%) tuy cũng thấp hơn nhiều nhưng mức độ chênh lệch nhẹ hơn so với Smooth Pursuit. Điều này phù hợp với phân tích ở mục 3.1-3.2: ranh giới giữa Fixation và Smooth Pursuit vốn không rõ ràng khi chỉ dùng vận tốc 1 chiều, do ảnh hưởng của vi cử động mắt.

Nguyên nhân chênh lệch này không xuất phát từ lỗi cài đặt thuật toán, mà đến từ các nguyên nhân kỹ thuật.

Hyperparameter không được paper công bố chi tiết:


- Số lượng thành phần Gaussian trong GMM-HMM không được ghi rõ trong bài báo.
- Loại ma trận hiệp phương sai: paper chỉ mô tả chung, trong khi code demo gốc dùng full. Với dữ liệu của một số participant còn hạn chế, ma trận full dễ gây suy biến, buộc nhóm phải hạ xuống diag để mô hình hội tụ ổn định.
- Phương pháp khởi tạo tham số ban đầu cho HMM trước khi chạy Baum - Welch không được nêu rõ.

Chiến lược train/test không rõ ràng: Paper không làm rõ việc huấn luyện tách riêng theo từng người hay gộp chung toàn bộ dữ liệu. Có khả năng nhóm tác giả gốc đã áp dụng tối ưu hóa sâu hơn, hoặc cách chia tập train/test khác với những gì nhóm tái hiện.







Tính chủ quan của nhãn thủ công: Việc gán nhãn hành vi mắt bằng tay vốn mang tính chủ quan cao - chính nhóm tác giả paper gốc cũng thừa nhận hạn chế này trong bài báo. Do đó, ground truth dùng để tính accuracy không mang tính tuyệt đối và có thể khác biệt giữa các đợt gán nhãn khác nhau, ảnh hưởng đến khả năng tái lập chính xác con số 94.39%.

b) Hoàn thiện pipeline từ mã nguồn của paper

Quan sát thực tế: Độ chính xác chênh lệch rất lớn giữa các tester (từ 43.8% đến 89.5%) dù chạy cùng 1 pipeline.




Giả thuyết: Để tìm nguyên nhân, nhóm so sánh trực quan phân phối vận tốc giữa một trường hợp accuracy thấp (tester08, 47.1%) và một trường hợp accuracy cao (tester11, 86.0%).




Trên trục $\log(\text{velocity})$, tester08 thể hiện mức độ chồng lấn (overlap) rõ rệt giữa Fixation và Smooth Pursuit, trong khi tester11 có ranh giới giữa ba lớp tách bạch hơn nhiều.

Cơ chế cải tiến: Bổ sung chiều gia tốc $|\Delta v|$ để tạo thành không gian đặc trưng 2D $[\log(v), \log|\Delta v|]$. Về mặt sinh học, Fixation có gia tốc biến thiên đột biến (do vi cử động micro-saccade) trong khi Smooth Pursuit có gia tốc thấp và đều đặn hơn. Nhờ đó, hai lớp vốn chồng lấn trên trục vận tốc được tách biệt rõ rệt hơn theo trục gia tốc - trục vuông góc bổ sung thêm thông tin phân biệt mà đặc trưng 1 chiều không có được.




c) Trực quan hóa kết quả

Sau khi áp dụng các cải tiến đã trình bày (mở rộng đặc trưng sang 2D $[\log(v), \log(\text{gia tốc})]$, xây mô hình nền participant-base, khởi tạo K-means, chuẩn hóa dữ liệu tăng 1...), độ chính xác tổng thể trên 18 participant tăng đáng kể so với baseline ban đầu.



Xét theo từng lớp hành vi, F1-score của cả ba lớp đều cải thiện rõ rệt so với bản 1D, đặc biệt là Smooth Pursuit — lớp từng tụt sâu nhất ở bản gốc (17.5%) — nay đạt 76.6%, thu hẹp đáng kể khoảng cách với paper (88.9%). Fixation đạt 91.0% (paper:

97.0%) và Saccade đạt 83.3% (paper: 90.8%), đều là mức tiệm cận khá tốt so với con số công bố.



Nhìn theo từng participant, cải tiến giải quyết triệt để vấn đề chênh lệch lớn đã nêu ở đầu mục 3.4b: toàn bộ 18/18 participant đều đạt accuracy trên 75%, trong đó 12/18 người đạt từ 85% trở lên (màu xanh), 6 người còn lại nằm trong khoảng 75–85% (màu vàng) — không còn trường hợp nào rơi xuống dưới 70% như ở bản 1D (tester02: 43.8%, tester08: 47.1%). Mức accuracy trung bình toàn nhóm đạt 85.6%, so với mốc mục tiêu 94.4% của paper, cho thấy khoảng cách còn lại chủ yếu đến từ các nguyên nhân khách quan đã giải trình ở mục 3.4a (hyperparameter không công bố, chiến lược train/test khác biệt, tính chủ quan của nhãn thủ công) chứ không phải do hạn chế của hướng cải tiến đặc trưng 2D.

Kết quả này khẳng định giả thuyết ban đầu của nhóm: chênh lệch accuracy giữa các participant chủ yếu bắt nguồn từ mức độ chòng lún vận tốc giữa Fixation và Smooth Pursuit, và bổ sung chiều gia tốc là hướng cải tiến hiệu quả để giải quyết vấn đề này.

4. KẾT LUẬN

Báo cáo đã tiến hành nghiên cứu cơ sở lý thuyết về K-means, Gaussian Mixture Model (GMM), Hidden Markov Model (HMM) và sự kết hợp GMM-HMM trong bài toán xử lý dữ liệu chuỗi. Trên cơ sở phương pháp được đề xuất trong paper, nhóm đã tìm hiểu và xây dựng lại pipeline phân loại chuyển động mắt, trong đó K-means kết hợp với SSE được sử dụng để hỗ trợ phân đoạn quỹ đạo, sau đó mô hình GMM-HMM phân cấp được áp dụng để xử lý và phân loại các trạng thái chuyển động mắt.

Dựa trên pipeline của paper và mã nguồn tham khảo, nhóm đã tiến hành hoàn thiện các bước xử lý và xây dựng ứng dụng demo, cho phép phân loại dữ liệu chuyển động mắt thành ba trạng thái gồm fixation, saccade và smooth pursuit. Bên cạnh đó, nhóm cũng thực hiện các thí nghiệm và đánh giá kết quả nhằm so sánh khả năng tái lập phương pháp với kết quả được công bố trong nghiên cứu gốc.

Thông qua quá trình nghiên cứu và triển khai, nhóm đã hiểu rõ hơn về cách kết hợp đặc trưng không gian, vận tốc và thông tin theo thời gian trong bài toán phân loại chuyển động mắt, cũng như vai trò của từng thành phần trong pipeline. Quá trình thực nghiệm cũng cho thấy việc tái lập một phương pháp từ paper phụ thuộc nhiều vào dữ liệu, cách tiền xử lý, tham số mô hình và các chi tiết trong quá trình triển khai.

5. TÀI LIỆU THAM KHẢO

- [1] Lawrence875, “eyemovement_classification_based_on_GMMHMM,” GitHub Repository. <https://github.com/lawrence875/eyemovement>.
- [2] J. Xie, R. Chen, Z. Liu, J. Zhou, J. Hou, and Z. Zhou, “GMM-HMM-Based Eye Movement Classification for Efficient and Intuitive Dynamic Human–Computer Interaction Systems,” *Journal of Eye Movement Research*, vol. 18, no. 4, Art. 28, 2025. DOI: 10.3390/jemr18040028.
- [3] D. A. Reynolds, “Gaussian Mixture Models,” *Encyclopedia of Biometrics*, Springer, 2009.
- [4] L. R. Rabiner, “A Tutorial on Hidden Markov Models and Selected Applications in Speech Recognition,” *Proceedings of the IEEE*, vol. 77, no. 2, pp. 257–286, 1989. DOI: 10.1109/5.18626.